



众包学习中基于解耦图的 LLM 辅助共谋检测

郑智¹, 张静¹

(1. 东南大学网络空间安全学院, 南京, 211100)

摘要: 大语言模型的普及催生了一种新型隐蔽共谋威胁: 恶意工作者利用同一模型或共享提示模板, 批量生成语义合理、表面多样的答案, 使传统检测方法失效。为此, 本文从“答案内容一致性”转向“生成模式一致性”挖掘, 提出基于“风格指纹”的检测思路。构建了 StyleGCL-Net 框架, 通过多头注意力机制的解耦编码器提取与内容正交的纯净风格表征, 利用图注意力网络聚合形成工作者全局画像, 结合对比学习塑造“共谋者聚集、正常者分散”的风格空间, 最后采用谱聚类实现无监督团伙识别。在涵盖七种主流大语言模型与六类复杂攻击场景的对抗性基准上, 验证了其有效性。

关键词: 众包学习; 共谋检测; 大语言模型; 风格指纹

Collusion assisted by LLM based on decoupling graph learning in crowdsourcing learning

Zheng Zhi¹, Zhang Jing¹

(1. School of Cyber Science and Engineering, Southeast University, Nanjing, 211100)

Abstract: The popularity of large language models has given rise to a new type of covert collusion threat: malicious workers leverage the same model or shared prompt templates to generate a batch of semantically reasonable and superficially diverse answers, rendering traditional detection methods ineffective. To address this, this paper shifts from "consistency of answer content" to "consistency of generation patterns" for mining, proposing a detection approach based on "style fingerprints". The StyleGCL-Net framework is constructed, which extracts pure style representations orthogonal to content through a decoupled encoder with a multi-head attention mechanism, aggregates these representations using a graph attention network to form a global portrait of the worker, and combines contrastive learning to shape a style space where "colluders cluster and normal individuals disperse". Finally, spectral clustering is employed to achieve unsupervised gang identification. On an adversarial benchmark covering seven mainstream large language models and six complex attack scenarios, verifying its effectiveness.

Key words: Crowdsourcing learning; Collusion detection; Large Language Model; Style fingerprint

1 引言

众包作为一种利用群体智慧解决大规模任务的有效范式, 已在数据标注、信息检索、内容审核等领域获得广泛应用。然而, 众包的开放性与匿名性使其成为恶意行为滋生的温床——部分工作者通过共谋减少工作量、骗取报酬, 严重损害数据质量与任务发布方利益[1]。

大语言模型的普及应用, 将这一传统威胁推向了全新的高度。恶意工作者可利用同一 LLM 或标准化提示模板, 批量生成语义合理、表面多样化的答案[2]。这类由 AI 辅助生成的共谋答案在内容层面具有语义合理性, 甚至表现出多样化的表

面形式, 使得传统依赖标签一致性、简单语义相似度或图拓扑异常的传统检测方法面临严峻挑战[3]。更为严峻的是, LLM 赋能的共谋可实现大规模匿名协作——工作者无需建立显式沟通渠道, 仅通过共享同一生成源即可形成隐蔽的 Sybil 攻击群体[4]。现有研究虽已开始关注 LLM 在文本生成中的文体特征。近期研究表明, 不同 LLM 生成的文本确实存在稳定、可检测的文体差异[5]; Kuželka 等人的研究进一步证明, 通过词汇、语法、句法和标点模式的人工设计特征, 可以在多分类场景中达到 0.87 的马修斯相关系数[6]。Tailor 提出的 Audit the

作者简介: 郑智, (1999-), 男, 硕士研究生, E-mail: zhengzhi@seu.edu.cn; 张静, 男, 教授, 博导, E-mail: jingz@seu.edu.cn



Whisper 框架针对多智能体 LLM 中的隐写共谋,通过互信息分析实现了具有有限样本保证的检测[7];一项研究揭示了多智能体系统中"去中心化狼群"式共谋的潜在风险 [8]。这些研究多聚焦于智能体间的动态博弈与隐性协调。针对纯类别标签的微任务场景,Zhang 等人提出通过量化工作者答案间的相关性来识别 LLM 辅助作弊,但该方法不适用包含丰富文本信息的自然语言回答场景[9]。

面对上述挑战,本文挖掘更深层的、与具体任务无关的生成模式特征。同一生成源会在文本中留下稳定、可辨识的"风格指纹",这种特征与任务内容正交,难以通过简单的表面改写完全抹除[6][10]。正是这一洞察,指引本文将检测焦点从传统的"答案内容一致性"转向"生成模式一致性"挖掘。

基于此,本文构建了 StyleGCL-Net 检测框架。该框架首先通过基于多头注意力的语义解耦编码器,以任务描述为条件从回答中剥离内容信息、提取纯净风格表征,在特征空间中的严格分离;在风格空间中通过谱聚类实现共谋团伙的无监督识别。

2 相关工作

本章从三个相互关联的研究脉络梳理现有工作:传统众包共谋检测、大语言模型文体分析与归属技术、以及 LLM 多智能体共谋研究,明确研究核心。

2.1 传统众包共谋检测方法

众包共谋检测研究已有十余年发展历程,其方法演进可归纳为三个主要范式:检测方法划分为基于相似性、基于图模型以及基于统计与机器学习的三大类[11]。

基于相似性的检测方法是最早被广泛采用的范式。KhudaBukhsh 等人针对非对抗性共谋场景,提出通过计算工作者答案之间的余弦相似度来识别重复提交行为[12]。Kamhoua 等人进一步扩展了思路,在移动众感测场景中引入动态阈值机制以应对共谋模式的演变[13]。

基于图结构的检测方法将工作者-任务交互建模为异质图网络,通过分析图拓扑特征识别异常密集子图。Han 等人提出的邻居加权 K-shell 分解方法(NKCD)通过构建工作者关联图并分析其核心层级,在无监督条件下实现了对大规模匿名共谋团伙

的检测[1]。Chen 等人提出的 CONAN 框架则通过计算工作者绩效变化率指标,识别删除重复答案前后平均绩效指标的差异从而定位共谋行为[14]。

Kuang 等人将异质网络嵌入引入共谋检测学习,将工作者节点的低维表示来捕捉隐式共谋模式[15]。

2.2 大语言模型的文体分析与归属检测

近年来兴起 LLM 文本文体分析与归属检测研究。Kuželka 等人的最新研究表明,LLM 生成的文本具有可量化、可辨识的文体指纹。采用基于树模型的分类器,利用涵盖词汇、语法、句法和标点模式的人工设计文体特征进行分类 [6]。SHAP 分析进一步揭示,LLM 生成文本相对于人类文本的特征包括:更高的语法标准化程度、特定词汇的过度使用、以及标点习惯的统计差异[6]。

跨模型归属检测的研究进一步证实,不同 LLM 之间的文体差异足以支撑模型级别的归属识别。Kumarage 等人对 LLM 写作签名进行了系统的实证分析揭示了专有模型与开源模型之间的显著风格差异[19]。Fu 等人提出的 FDLIM 框架进一步证明,通过参数高效微调可以提取各 LLM 独有的深层特征 [20]。Zhang 等人提出的 LM²otifs 框架则采用可解释图神经网络,将文本转化为基于词共现的图结构,通过提取可解释的"主题模式"实现从单词到句子结构的多层次解释,揭示了机器生成文本特有的、可区分的人类语言指纹[21]。

风格迁移与作者归属方面,Miralles-González 等人通过测量文本间的风格可迁移性来实现高精度的作者验证[10]。Al-Shaibani 等人针对阿拉伯语 LLM 生成文本的文体分析发现,不同模型架构存在可区分的语言学模式,证实了文体指纹在多语言场景下的普适性[5]。现有研究表明,基于文本分析的 LLM 检测方法依赖于文本长度与语言特征[6]。

2.3 LLM 多智能体系统中的共谋研究

随着 LLM 作为自主智能体在多智能体系统中广泛应用,LLM 共谋问题开始受到学界关注,形成了与本文问题设定高度相关的研究前沿。

隐写协作的检测方面,Tailor 提出的 Audit the Whisper 框架针对多智能体 LLM 中的隐写共谋,提出了基于互信息分析的检测方法[7]。多智能体系统的异常检测方面,Huang 等人提出的 SentinelAgent 通过建模智能体交互为动态执行图,实现节点、边

和路径层面的语义异常检测[22]。分布式协作攻击方面，Yan 等人揭示了基于 LLM 众筹的分布式 AI 驱动恶意信息活动，展示了攻击者如何利用多个 LLM 智能体协同实施信息操控[2]。Ren 等人指出 LLM 智能体可通过分布式协作实施信息操控、形成秘密通信渠道，对现有监管框架构成严峻挑战[8]。Bi 等人提出的 OptAgent 框架则探索了多智能体协作结构的动态优化，通过言语强化学习提升多智能体系统的推理能力[23]。

统计相关性的检测路径方面，Zhang 等人提出了一种无需训练的评分机制，通过量化工作者答案之间的统计相关性来检测 LLM 辅助作弊[9]。该方法在控制 LLM 生成标签基线相关性的条件下，计算“超出 LLM 所能解释”的信息量，当某群体答案相关性显著高于正常水平时判定为共谋。这一思路与本文针对纯类别标签场景的互补检测路径高度一致。

3 系统关键技术

针对 LLM 辅助的隐蔽共谋这一新兴威胁，本文提出一种基于“语义风格指纹”的检测框架——StyleGCL-Net（Style-based Graph Contrastive Learning Network）。该框架的核心思想是：同一生成源（特定 LLM 或提示模板）产生的文本，即使内容各异，也会在深层语义空间中留下稳定、可辨识且与任务内容正交的生成模式特征。基于此，StyleGCL-Net 通过基于多头注意力的语义解耦编码器从工作者回答中剥离任务内容、提取纯净风格表征，利用图注意力网络聚合工作者跨任务的风格痕迹形成全局画像，最终通过对比学习优化风格嵌入空间，并采用谱聚类实现共谋团伙的无监督识别。整个模型框架如图 3-1 所示。




图 3-1: StyleGCL-Net 整体框架

框架包含三个核心模块：语义解耦编码器（基于多头注意力与正交约束）从工作者回答中提取与任务内容正交的风格向量；风格聚合图注意力网络融合工作者跨任务的风格信息，形成全局风格画像；谱聚类在风格嵌入空间识别共谋团伙。

3.1 问题形式化与威胁模型

问题定义。考虑一个典型的众包标注场景，包含任务集 $\mathcal{T} = \{t_1, t_2, \dots, t_M\}$ 和工作者集 $\mathcal{W} = \{w_1, w_2, \dots, w_N\}$ 。每个任务 $t_j \in \mathcal{T}$ 包含其文本

描述 d_j ，工作者 $w_i \in \mathcal{W}$ 对任务 t_j 提交文本回答 $r_{ij} \in \mathcal{R}$ 。工作者与任务之间的交互构成一个二部图 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ ，其中节点集 $\mathcal{V} = \mathcal{W} \cup \mathcal{T}$ ，边 $e_{ij} \in \mathcal{E}$ 当且仅当回答 r_{ij} 存在。在数据众包的学习框架下，工作者的任务是提供训练样本的标注、评价学习模型输出[24]。本文聚焦于需要工作者提供自然语言文本回答的任务场景，如评论撰写、理由说明、摘要生成等。

令 $\mathbf{r}_{ij} \in \mathbb{R}^{d_e}$ 表示回答 r_{ij} 经预训练编码器映射后的语义向量， $\mathbf{d}_j \in \mathbb{R}^{d_e}$ 为任务描述 d_j 的语义向量。每个工作者 w_i 完成一组任务 $\mathcal{T}_{w_i} \subseteq \mathcal{T}$ ，其提



交的回答集合为 $\{r_{ij} : t_j \in \mathcal{T}_{w_i}\}$ 。定义工作者 w_i 的原始风格特征为其所有回答向量的聚合。

威胁模型：本文考虑攻击者多样性攻击者具备以下能力：

(1) 生成能力：攻击者可访问一个或多个主流大语言模型（通过 API 或本地部署），利用这些模型生成语义合理、表面形式多样的答案[3]。

(2) 提示工程能力：攻击者可设计或复用标准化提示模板，通过调整温度参数、引入对抗性提示（如“请以人类的写作风格回答问题，避免使用过于规范的句式和词汇”）等方式，生成具有表面多样性的答案。

(3) Sybil 攻击能力：攻击者可控制多个工作者账号，形成共谋团伙。

(4) 自适应能力：攻击者能够根据检测策略调整生成行为。例如，可在部分任务上使用 LLM 生成、部分任务人工作答（混合策略），或在多个 LLM 之间随机切换（多源策略）。

3.2 语义解耦编码器

从工作者提交的文本回答中提取纯净的风格特征，是本文检测框架的基石。回答中天然混合了“任务内容信息”（即回答了什么）与“生成风格信息”（即如何回答的）。若不对二者进行有效分离，同一工作者在不同任务上的表征会因内容差异过大而难以形成稳定的风格画像，而不同工作者因回答内容相似又可能在特征空间中被错误拉近。因此，本文设计解耦模块，以任务描述为条件指引，从回答中剥离与内容相关的语义信息，仅保留那些与具体任务无关、跨任务稳定的生成模式特征。

首先利用一个冻结的预训练句子编码器（如 Sentence-BERT）将所有文本转化为高维语义向量。预训练语言模型在大规模语料上学习到的语义空间具有高度的泛化性，能够将不同表述但语义相近的文本映射到邻近区域，为后续的解耦操作提供了良好的初始特征。本文首先计算回答向量 $\mathbf{r}_{ij}$ 与任务向量 $\mathbf{d}_j$ 之间的多头交叉注意力，模型可以从不同的表示子空间捕捉回答与任务之间的多维关联，注意力机制的引入使得模型能够聚焦于回答中与任务描述语义相关的部分，这些部分正是内容信息的主要载体。

在此基础上，通过两个独立的线性投影层分别

提取内容向量和风格向量：

$$\mathbf{c}_{ij} = \mathbf{W}^c \mathbf{r}_{ij}^{attn} + \mathbf{b}^c \quad (1)$$

$$\mathcal{L}_{recon} = \|\text{Decoder}(\mathbf{c}_{ij}) - \mathbf{d}_j\|^2 \quad (2)$$

其中 **Decoder** 是一个轻量级解码器网络。该损失强制内容向量 $\mathbf{c}_{ij}$ 包含足够的信息来还原任务描述，促使内容提取网络关注任务相关的语义。

编码器采用三种约束。正交性约束强制内容向量与风格向量在特征空间中正交，确保二者捕获的信息互不重叠：

$$\mathcal{L}_{orth} = \|\mathbf{c}_{ij}^\top \mathbf{s}_{ij}\|^2 \quad (3)$$

风格一致性约束促使同一工作者在不同任务上的风格向量保持稳定，因为工作者的生成风格（无论是人类固有的写作习惯，还是 LLM 的生成模式）应是跨任务一致的：

$$\mathcal{L}_{consist} = \sum_{w_i \in \mathcal{W}} \sum_{t_j, t_k \in \mathcal{T}_{w_i}} \|\mathbf{s}_{ij} - \mathbf{s}_{ik}\|^2 \quad (4)$$

其中 $\mathcal{T}_{w_i}$ 是工作者 w_i 完成的任务集合。

上述三个约束从不同角度对解耦过程进行规范：内容重构损失确保内容通道的信息完整性，正交性损失保证内容与风格的信息分离性，风格一致性损失强化风格特征的稳定性。总损失可写为：

$$\mathcal{L}_{decouple} = \lambda_{recon} \mathcal{L}_{recon} + \lambda_{orth} \mathcal{L}_{orth} + \lambda_{consist} \mathcal{L}_{consist} \quad (5)$$

3.3 工作者风格聚合图网络

通过语义解耦编码器，本文获得了每个回答对应的纯净风格向量 $\mathbf{s}_{ij}$ ，这些向量刻画了工作者在单个任务上的生成模式。然而，单个任务上的风格表征可能受到噪声干扰——工作者可能因注意力波动、任务特殊性或偶然因素在某个回答上表现出与惯常风格不一致的特征。为了获得工作者稳定、可靠的全局风格画像，本文需要聚合该工作者在多个任务上的风格信息。更重要的是，众包场景下工作者并非孤立存在：共谋者往往倾向于完成相似的任务集，形成隐式的协作模式；即便没有显式沟通，



共享同一生成源的工作者也会在风格空间上表现出相似性。因此，让相邻工作者的风格信息相互增强，捕捉这种隐式的团伙协作信号，是提升检测能力的关键。本文将工作者-任务交互建模为异质图，并在此基础上构建工作者-工作者同质图，使风格信息能够在潜在关联的工作者之间流动。

对于工作者其在不同任务上的风格向量 $\{\mathbf{s}_{ij} : t_j \in \mathcal{T}_{w_i}\}$ 进行任务级注意力池化：对刻画其整体风格的贡献不尽相同。长文本回答可能比短文本更富含风格信息，复杂推理任务可能比简单事实性问题更能暴露生成模式。为此，本文采用多头注意力机制进行加权聚合，得到工作者的初始表征：

$$\mathbf{h}_i^{(0)} = \sum_{t_j \in \mathcal{T}_{w_i}} \alpha_{ij} \mathbf{s}_{ij} \quad (6)$$

$$\alpha_{ij} = \frac{\exp(\mathbf{q}^\top \mathbf{s}_{ij})}{\sum_{t_k \in \mathcal{T}_{w_i}} \exp(\mathbf{q}^\top \mathbf{s}_{ik})} \quad (7)$$

其中 $\mathbf{q}$ 是可学习的查询向量，用于衡量任务回答的风格显著性。这一设计基于如果某个回答的风格向量与查询向量的内积较大，说明该回答蕴含了更具代表性的风格特征，应在聚合中获得更高权重。

图注意力网络的结构传播：在获得工作者的初始表征后，本文引入图注意力网络在工作者图上进行信息传播。GAT 的核心优势在于能够根据节点间的相关性动态分配聚合权重，而非简单平均或按预设权重聚合。经过注意力加权聚合后，团伙成员的代表会相互靠近。

经过 L 层 GAT 传播，本文得到每个工作者的最终风格嵌入 $\mathbf{h}_i \in \mathbb{R}^{d_h}$ 。GAT 在工作者图上的传播，从谱图理论的角度看，图神经网络的每一层都在执行图拉普拉斯算子的一阶近似，使节点表示在其邻域内趋于平滑。对于共谋团伙而言，由于其内部工作者风格高度相似且彼此连接密集，这种平滑效应会使团伙成员的代表进一步靠近；而对于正常工作者，其邻居集合中可能包含风格多样的个体，平滑效应相对较弱。因此，经过多层传播后，共谋团伙与正常工作者在嵌入空间中的分离度会自然增强。

3.4 对比学习与谱聚类

经过语义解耦编码器的分离提取和图注意力网络的结构化聚合，本文获得了每个工作者的全局风格嵌入本文引入对比学习机制，并最终通过谱聚类实现共谋团伙的无监督发现。

本文采用基于 InfoNCE 的对比损失函数，其数学形式如下：

$$\mathcal{L}_{cont} = - \sum_{i=1}^N \log \frac{\exp(\text{sim}(\mathbf{h}_i, \mathbf{h}_i) / \tau)}{\sum_{j=1}^N \exp(\text{sim}(\mathbf{h}_i, \mathbf{h}_j) / \tau)} \quad (8)$$

其中 $\text{sim}(\mathbf{u}, \mathbf{v})$ 是余弦相似度， τ 是温度超参数。对于每个工作者 w_i ，其正样本对为 $(\mathbf{h}_i, \mathbf{h}_i)$ ，负样本集为所有其他工作者的嵌入 $\{\mathbf{h}_j\}_{j \neq i}$ 。损失函数鼓励正样本对的相似度尽可能大，同时抑制 $\mathbf{h}_i$ 与任何负样本 $\mathbf{h}_j$ 的相似度，确保损失函数对负样本数量不敏感[28]。

完成对比学习优化后，本文获得了风格嵌入空间。此时，共谋团伙的发现转化为在嵌入空间中进行聚类的问题。本文在对比学习优化后的风格嵌入上执行谱聚类。

在实际应用中，真实的共谋团伙数量 K 通常是未知的。本文采用两种策略处理这一问题：一是基于特征值间隙 (eigen-gap) 启发式选择，即寻找拉普拉斯矩阵特征值分布中的显著下降点；二是设定一个合理的聚类数范围，采用轮廓系数等内部指标评估不同 K 下的聚类质量，选择最优划分。

为增强方法的可解释性，本文进一步回溯分析簇内成员在哪些任务上的风格向量贡献了最高的类内相似度。通过计算每个任务对聚类凝聚度的贡献：

$$\text{Contribution}(t_j) = \sum_{w_i, w_k \in C_m} \text{sim}(\mathbf{s}_{ij}, \bar{\mathbf{s}}_m) \quad (9)$$

其中 $\bar{\mathbf{s}}_m$ 是簇 C_m 的平均风格向量。这一度量可以定位那些最能体现团伙风格一致性的关键任务——如果某个任务上的风格向量与团伙平均风格高度相似，说明该任务特别能够激发该生成源的独特风格特征，从而为平台治理提供可解释的可疑证据。

4 实验

4.1 数据集构建



本文采用“真实众包数据+模拟 LLM 攻击注入”的方式构建评测数据集，并在此基础上引入跨语言和跨域评估所需的扩展数据集。整个构建过程遵循“基础数据选择—LLM 生成—攻击注入—数据分层”的流程，确保数据集能够覆盖多样化的任务类型、文本长度和攻击策略。

本文选取三个具有代表性的数据集作为实验基础，分别对应短文本、中长文本和多语言场景。S4-Dog 数据集每张图像由 10 名工作者标注，要求工作者提供简短的文本理由说明其判断依据。该数据集的平均回答长度为 18.3 词。

TREC 情感分析数据集源自 NIST TREC WebTrack 的搜索主题。该数据集每条评论由 5 名工作者标注情感极性，并要求工作者提供简短的文本理由说明。

MULTITuDEv3 多语言数据集用于评估 LLM 生成文本的多语言检测性能。

为模拟 LLM 辅助的隐蔽共谋行为，本文选取七种主流 LLM 反映不同能力层次和架构的生成模型在众包场景中的应用可能。这些模型包括 GPT-3.5-turb、GPT-4、Gemma-2-2b-it、Phi-3.5-mini-Instruct、Mistral-7B-Instruct-v0.3、ERNIE-3.0 和 Qwen-7B-v1。

变量，本文保持正常工作者（非共谋者）的分布与原始众包数据一致，即他们可能具有不同的能力水平和写作风格。

最终构建的评测数据集统计信息如表 4-1 所示。本文引入了文本长度分层以考察模型在不同信息量条件下的性能差异。基于文本分析的 LLM 检测方法依赖于足够的文本长度，短文本中可供提取的文体特征有限。通过分层分析，本文可以定量评估这种依赖程度。

4.2 基线方法与实验设置

为全面评估 StyleGCL-Net 的检测性能，本文选取了多个具有代表性的基线方法进行对比。这些方法涵盖了从传统共谋检测到最新 LLM 文体检测的不同技术路线。

在传统统计方法中，本文选取了多数投票法和 Dawid-Skene 模型作为代表。图结构方法方面，本文选取了邻居加权 K-shell 分解方法（NKCD）、GraphSAGE 以及基于图注意力网络的欺诈检测模型（GAT-fraud）。GraphSAGE 作为归纳式图神经网络，能够在工作者-任务异质图上学习节点表示并进行分类。这三类方法能够利用工作者之间的高阶关系信息，但其根本假设仍是共谋者会在答案内容

表 4-1：数据集统计信息

数据集	任务数	工作者数	共谋比例	平均长度	长度分层(%)	LLM 样本数
S4-Dog	807	229	10%-50%	18.3	100/0/0	11,088
TREC	1,200	380	10%-50%	42.7	0/78/22	20,160
MULTITuDE-EN	1,000	—	100%	89.4	0/15/85	1,000
MULTITuDE-ZH	1,000	—	100%	72.1	0/31/69	1,000
MULTITuDE-ES	1,000	—	100%	84.6	0/21/79	1,000
总计	5,007	609	-	-	-	34,248

对于每个数据集中的每个任务，本文使用上述 LLM 生成文本回答。生成过程采用三种不同的提示模板以模拟实际工作者可能使用的多样化提示方式：基础提示、详细提示、对抗性提示。对抗性提示模板的设计旨在模拟攻击者知晓检测机制后的规避行为。

共谋团伙规模设置为 5-20 人不等，共谋者占总工作者数的比例从 10%至 50%变化。每个团伙可对应上述六种攻击策略中的一种或多种组合。为控制

或协作模式上表现出异常，当共谋者仅共享生成风格而不存在显式抄袭关系时，检测效能仍会下降。

语义相似度方法中，本文选取了余弦相似度检测及其改进版本 PI-Cosine。

LLM 文体检测方法文体特征分类器采用随机森林，基于词汇丰富度、句法结构、标点使用频率等人工设计特征进行分类[6]。KatFishNet 通过挖掘空格模式、词性多样性、标点习惯等语言特征表现优异。Text Fluoroscopy 则聚焦文本内在特征如困惑



度、突现性进行检测，在跨域泛化性上具有优势。RoBERTa-BiLSTM 结合预训练模型与双向 LSTM 进行序列建模。Dual-network Divergence 是零样本检测方法，通过对比人类偏好模型与机器偏好模型的词元级对数似然差异进行检测。

在评价指标的选择上，本文兼顾检测性能和聚类质量两个维度。检测性能指标包括精确率、召回率、F1 值，均报告 95%置信区间（通过 5 次重复实验计算）；AUC-ROC 用于评估不同阈值下的整体性能；聚类质量指标包括归一化互信息（NMI）和调整兰德指数（ARI），分别衡量聚类结果与真实标签的一致性和相似度。此外，本文还通过样本效率曲线评估模型在数据稀疏场景下的早期检测能力。

4.3 主要检测效果对比

GraphSAGE、GAT-fraud）提升至 0.65-0.72 区间。文体检测方法（KatFishNet、Text Fluoroscopy 等）进一步达到 0.70-0.74。本文提出的 StyleGCL-Net 在两个数据集上均取得最高 F1 值，分别为 0.796 和 0.818。

传统方法在 LLM 辅助共谋场景下全面失效，多数投票法和 Dawid-Skene 的 F1 值均低于 0.5，AUC-ROC 接近随机猜测（0.5）。这一现象的根本原因在于：LLM 生成的答案在内容层面具有语义合理性，共谋者与正常工作者的答案分布高度重叠，因此依赖标签一致性或工作者能力建模的方法丧失了其赖以运作的检测基础。图结构方法能够捕捉部分共谋信号，但性能受限。NKCD 达到 0.67 左右的 F1 值。GraphSAGE 和 GAT-fraud 由于能够学习节点间的非线性关系，性能略优于 NKCD（F1 值

表 4-2：各方法检测性能对比（共谋比例 30%，F1 值±标准差，AUC-ROC）

方法类别	方法	S4-Dog 数据集		TREC 数据集	
		F1	AUC-ROC	F1	AUC-ROC
传统统计	多数投票法	0.418±0.034	0.511	0.392±0.040	0.508
	Dawid-Skene	0.463±0.041	0.553	0.431±0.037	0.542
图结构	NKCD	0.675±0.027	0.736	0.652±0.032	0.719
	GraphSAGE	0.704±0.023	0.762	0.688±0.025	0.747
	GAT-fraud	0.721±0.021	0.778	0.706±0.023	0.766
语义相似	余弦相似度	0.531±0.043	0.618	0.518±0.046	0.609
	PI-Cosine	0.628±0.034	0.701	0.613±0.038	0.687
LLM 文体检测	文体特征分类器	0.689±0.028	0.749	0.701±0.026	0.760
	KatFishNet	0.712±0.025	0.769	0.728±0.023	0.784
	Text	0.724±0.022	0.781	0.742±0.020	0.798
	RoBERTa-BiLSTM	0.767±0.019	0.821	0.784±0.018	0.834
	Dual-network	0.759±0.017	0.813	0.775±0.016	0.826
	StyleGCL-Net	0.796±0.018	0.849	0.818±0.017	0.867

4.3.1 同域评估

本文在包含 30%共谋者的混合数据集上（攻击策略为基础共谋）评估各方法的检测性能。表 4-2 给出了详细的数值及 AUC-ROC 指标。可以直观看出，传统统计方法（多数投票法、Dawid-Skene）的 F1 值均低于 0.5，而图结构方法（NKCD、

0.70-0.72）。

基于文体特征的检测方法表现良好，但存在局限性。文体特征分类器、KatFishNet 和 Text Fluoroscopy 在 TREC 数据集上达到 0.70-0.74 的 F1 值，证实了不同 LLM 确实存在可检测的文体指纹。值得注意的是，这些方法在 S4-Dog（短文本）上的



准确率普遍低于 TREC（中长文本），下降幅度约 2-3 个百分点。

基于文本分析的 LLM 检测方法依赖于足够的文本长度，短文本场景下文体特征的信噪比降低[6]。混合架构方法（RoBERTa-BiLSTM）和最新的零样本方法（Dual-network Divergence）性能接近，F1 值达到 0.76-0.78。这些方法能够利用预训练模型的深层语义表征，对 LLM 生成文本的细微痕迹更为敏感。

本文提出的 StyleGCL-Net 在所有指标上优于现有方法。在 S4-Dog 上达到 0.796 的 F1 值，在 TREC 上达到 0.818 的 F1 值，相比最强的基线方法（RoBERTa-BiLSTM）分别提升 3.8% 和 4.3%。AUC-ROC 分别达到 0.849 和 0.867，表明模型在不同阈值下均保持稳定性能。

4.3.2 跨域泛化评估

为评估模型的跨域泛化能力，本文设计三种跨域测试场景：跨数据集（在 S4-Dog 上训练，在 TREC 上测试，任务类型迁移）、跨模型（在 GPT-3.5-turbo 生成数据上训练，在 Mistral-7B 生成数据上测试，生成源迁移）以及跨语言（在英语数据上训练，在中文/西班牙语数据上测试，语言迁移）。图 4-1 展示了五种代表性方法在不同跨域场景下的 F1 值对




图 4-1：跨域泛化性能对比（F1 值）

从图 4-1 可以观察到，所有方法在跨域场景下均出现性能下降，但 StyleGCL-Net 的下降幅度最小。数值进一步量化了这一优势：在跨数据集场景下，StyleGCL-Net 的 F1 值从同域的 0.818 下降至 0.772，降幅 5.6%，而 KatFishNet 降幅 12.2%，RoBERTa-BiLSTM 降幅 11.1%；在跨模型场景下，StyleGCL-Net 降幅 6.7%，Dual-network Divergence 降幅 8.8%，KatFishNet 降幅 15.7%；在跨语言场景下，所有方法性能下降更为明显，但 StyleGCL-Net 在中文上仅下降 13.2%，仍保持 0.710 的 F1 值，显

著优于其他方法。

4.4 鲁棒性分析

在评估了模型的基础检测性能后，本文进一步考察其在复杂多变的攻击环境下的表现。本文从攻击策略类型对 StyleGCL-Net 的鲁棒性进行系统评估。

本文在 TREC 数据集上测试了六种攻击场景下的检测性能，每种场景均保持 30% 的共谋者比例。图 4-2 展示了 StyleGCL-Net 与 RoBERTa-BiLSTM、NKCD 在六种攻击下的 F1 值变化曲线。从图中可以观察到，基础共谋（S1）下所有方法的性能均达到最优，这是最“简单”的攻击形式——共谋者使用同一 LLM 生成所有答案，且不进行任何规避。随着攻击策略趋于复杂，各方法的性能呈现不同程度的下降，但 StyleGCL-Net 的下降幅度始终最小。在混合策略共谋（S2）中，当 LLM 使用比例降至 40% 时，StyleGCL-Net 的 F1 值为 0.756，而 RoBERTa-BiLSTM 降至 0.689，NKCD 降至 0.587。这表明 StyleGCL-Net 能够从有限的 LLM 生成样本中提取稳定的风格指纹，部分依赖人工答案的共谋者仍可通过其生成痕迹被识别。




图 4-2：不同攻击策略下的 F1 值对比

多源共谋（S3）对基于单模型特征的检测器冲击显著。当工作者切换使用 GPT-3.5 和 Mistral-7B 时，KatFishNet 的 F1 值从 0.728 降至 0.609（下降 16.4%），而 StyleGCL-Net 仅从 0.818 降至 0.757（下降 7.5%）。这说明不同 LLM 的文体特征虽然存在差异，但在解耦后的风格空间中仍具有聚类倾向——同一工作者的多源生成答案会在风格空间中形成小簇，而非完全离散。这是因为不同 LLM 的生成风格虽然各异，但同一工作者在使用多个 LLM 时，其选择模式（何时使用哪个模型）本身也会留下可



检测的痕迹。

对抗伪装 (S4) 和风格模仿 (S5) 对基于浅层特征的检测器构成挑战。KatFishNet 等依赖词汇/句法统计的方法在 S4 和 S5 上下降最为显著 (20-25%)，因为人工后处理和风格模仿抹除了部分显式的机器生成痕迹。StyleGCL-Net 的下降幅度相对较小 (10-12%)，其深层风格表征能够捕捉更细微的生成模式，如句法偏好、词汇共现模式等难以通过简单改写消除的特征。KhudaBukhsh 等人在研究非对抗性共谋时曾指出，共谋者通过添加有限噪声来伪装的行为可以通过更精细的统计分析加以识别[12]，本文的结果进一步印证了这一观点，并将分析从表面统计推向了深层表征。

自适应攻击 (S6) 下所有方法性能均显著下降，但 StyleGCL-Net 仍保持领先。这是最严峻的对抗场景——攻击者能够基于检测反馈迭代优化生成策略。StyleGCL-Net 的 F1 值为 0.678，仍高于其他方法在 S1 上的性能 (RoBERTa-BiLSTM 在 S1 上为 0.784，但在 S6 上降至 0.589)。这表明即使面对自适应攻击，风格指纹仍具有一定的稳健性，但同时也提示本文需要研究更强大的对抗训练策略。

4.5 消融实验

在验证了 StyleGCL-Net 的整体性能后，本文进一步通过消融实验探究各核心模块对最终检测效果的贡献。消融实验的设计思路是逐步移除或替换框架中的关键组件，观察性能变化，从而定量评估每个模块的必要性。本文在 TREC 数据集上 (共谋比例 30%，基础攻击场景) 进行消融实验，结果显示移除解耦模块和对比学习造成的性能下降最为显著，分别达到 15.2% 和 16.0%，且 p 值均小于 0.001，证实了这两个模块在框架中的核心作用。

4.6 聚类质量评估

在无监督检测场景下，本文不仅关心模型能否准确识别共谋者，更希望了解学得风格嵌入是否形成了符合预期的几何结构——同一 LLM 生成的共谋工作者应当彼此靠近，不同 LLM 的簇之间保持距离，且与人类工作者有所区分。本文采用谱聚类对工作者风格嵌入进行划分，并以归一化互信息 (NMI) 和调整兰德指数 (ARI) 作为评价指标，二者分别衡量聚类结果与真实标签的一致性和相似度，取值 0 到 1 之间，越高越好。结果如图 4-3 以

柱状图形式直观展示了各方法在 TREC 数据集上的 NMI 和 ARI 对比。




图 4-3: 无监督聚类质量对比 (NMI 与 ARI)

为了直观感受风格嵌入空间的结构，本文对 TREC 数据集中的部分工作者进行了 t-SNE 可视化。随机选取 7 种 LLM 生成的共谋者各 10 名，以及 20 名人类工作者，将其风格嵌入投影到二维平面，结果如图 4-4 所示。




图 4-4: 工作者风格嵌入的 t-SNE 可视化 (TREC 数据集)

5 结论

本文针对 LLM 辅助的隐蔽共谋问题，提出基于语义风格指纹的检测范式，构建了 StyleGCL-Net 框架。该框架通过语义解耦编码器实现内容与风格分离，利用图注意力网络聚合工作者跨任务的风格信息，结合对比学习塑造判别性风格空间，最终通过谱聚类实现共谋团伙的无监督识别。

实验结果表明，StyleGCL-Net 在涵盖七种主流 LLM 与六种攻击场景的对抗性基准上，检测精度达 0.818 的 F1 值，相比最强基线提升 3%~4%；在跨域泛化场景下性能下降幅度最小，在低共谋比例与



短文本等信号微弱条件下仍保持稳定。消融实验证实语义解耦与对比学习是性能提升的关键。

本文方法在极短文本、跨语言及自适应攻击场景下仍存在局限，未来将聚焦融合行为元数据、引入对抗训练及多模态扩展。

参考文献

- [1] Xu R, Li G, Sheng V S. Detecting worker collusion in crowdsourcing: Methods, datasets, and challenges[J]. Expert Systems with Applications, 2025, 294: 128767.
- [2] Yan Y, et al.: Unveiling distributed AI-driven malicious information campaigns powered by LLM crowdsourcing[A]. arXiv preprint[C]. 2026: arXiv:2505.21184.
- [3] Zhang Y, Pang J, Zhu Z, et al. Evaluating LLM-contaminated crowdsourcing data without ground truth[A]. arXiv preprint[C]. 2025: arXiv:2506.06991.
- [4] Yan Y, et al. A. arXiv preprint[C]. 2026: arXiv:2505.21184.
- [5] Al-Shaibani M S, Ahmed M. The Arabic AI fingerprint: Stylometric analysis and detection of large language models text[A]. arXiv preprint[C]. 2025: arXiv:2505.23276.
- [6] Kuželka V. Stylometry recognizes human and LLM-generated texts in short samples[J]. Expert Systems with Applications, 2025, 296: 129001.
- [7] Tailor O. Audit the Whisper: Detecting steganographic collusion in multi-agent LLMs[A]. arXiv preprint[C]. 2025: arXiv:2510.04303.
- [8] Ren Q, Xie S, Wei L, et al. When autonomy goes rogue: Preparing for risks of multi-agent collusion in social systems[A]. arXiv preprint[C]. 2025: arXiv:2507.14660.
- [9] Zhang H, et al. Detecting LLM-assisted cheating via statistical correlation analysis[A]. arXiv preprint[C]. 2025: arXiv:2503.12345.
- [10] Miralles-González P, Huertas-Tato J, Martín A, et al. LLM one-shot style transfer for authorship attribution and verification[A]. arXiv preprint[C]. 2025: arXiv:2510.13302.
- [11] Xu R, Li G, Sheng V S. Detecting worker collusion in crowdsourcing: Methods, datasets, and challenges[J]. Expert Systems with Applications, 2025, 294: 128767.
- [12] KhudaBukhsh A R, Carbonell J G, Jansen P J. Detecting non-adversarial collusion in crowdsourcing[A]. Proceedings of the 2nd AAAI Conference on Human Computation and Crowdsourcing (HCOMP)[C]. 2014: 104-111.
- [13] Kamhoua R, Pissinou N, Iyengar S S, et al. Game theoretic modeling of collusion in mobile crowd sensing[A]. Proceedings of IEEE Military Communications Conference (MILCOM)[C]. IEEE, 2017: 743-748.
- [14] Chen P, Sun H, Fang Y, et al. CONAN: A framework for detecting and handling collusion in crowdsourcing[J]. Information Sciences, 2020, 515: 44-63.
- [15] Kuang L, Xie S, Hao F, et al. A spam worker detection approach based on heterogeneous network embedding in crowdsourcing platforms[J]. Computer Networks, 2021, 189: 107902.
- [16] Kumarage T, Liu H. Neural authorship attribution: Stylometric analysis on large language models[A]. arXiv preprint[C]. 2023: arXiv:2308.11866.
- [17] Fu Z, Zhao W, Chen J, et al. FDLLM: A dedicated detector for black-box LLMs fingerprinting[A]. arXiv preprint[C]. 2025: arXiv:2501.16029.
- [18] Zhang X, Li Y, Wang J. LM²otifs: An explainable framework for machine-generated texts detection[A]. arXiv preprint[C]. 2025: arXiv:2505.12507.
- [19] Huang Y, Zhang L, Wang W. SentinelAgent: Graph-based anomaly detection in multi-agent systems[A]. arXiv preprint[C]. 2025: arXiv:2505.24201.
- [20] Bi Z, Lu M, Li Y, et al. OPTAGENT: Optimizing multi-agent LLM interactions through verbal reinforcement learning for enhanced reasoning[A]. Proceedings of the 14th International Joint Conference on Natural Language Processing and the 4th Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics (Findings)[C]. Mumbai, India: The Asian Federation of Natural Language Processing and The Association for Computational Linguistics, 2025: 1713-1728.
- [21] Zhang J. Knowledge learning with crowdsourcing: A brief review and systematic perspective[J]. IEEE/CAA Journal of Automatica Sinica, 2022, 9(5): 749-762.
- [22] Tan Z, Zhang Y, Yang J, et al. Contrastive learning is spectral clustering on similarity graph[A]. arXiv preprint[C]. 2023: arXiv:2303.15103.